

Optimización del número de clusters para la clasificación de imágenes de rostros mediante Firefly Algorithm y Particle Swarm Optimization.

Santiago Mendivelso, Andres Moreno, Federico Molano

March 2025

1 Contexto y relevancia

En la sociedad actual, el reconocimiento y la clasificación de rostros representan un desafío significativo, tanto en el ámbito privado, mediante soluciones biométricas como el desbloqueo facial de dispositivos y el etiquetado en redes sociales, como en el ámbito público, en aplicaciones de seguridad y vigilancia. En el contexto del aprendizaje automático, un clúster es un conjunto de datos que comparten características similares. En el caso de imágenes faciales, cada clúster puede agrupar rostros con atributos comunes, lo que facilita su clasificación y reconocimiento dentro de una base de datos. Por ejemplo, si un conjunto de datos contiene 100 imágenes y el algoritmo genera 5 clústeres, esto indicaría que hay 5 personas diferentes en la base de datos, y que cada una de ellas tiene aproximadamente 20 imágenes asociadas.

Una segmentación precisa de las imágenes faciales en clústeres mejora el rendimiento de los algoritmos de clasificación y permite identificar patrones dentro de grandes volúmenes de información visual. No obstante, determinar el número óptimo de clústeres en estos conjuntos de datos sigue siendo un reto. Este proyecto busca abordar este problema mediante el uso de algoritmos bioinspirados, como el Firefly Algorithm (FA) y Particle Swarm Optimization (PSO), con el objetivo de optimizar la clasificación en términos de precisión y eficiencia computacional.

2 Contexto y relevancia

¿Por qué este problema es relevante? La optimización del número de clusters es crucial para mejorar la clasificación de imágenes faciales y reducir el ruido en la segmentación. En aplicaciones como la seguridad y el reconocimiento biométrico, una clasificación precisa de rostros es fundamental para evitar errores de identificación.

¿Qué impacto tiene su resolución en el contexto actual? La optimización del número de clusters impacta significativamente en la calidad de los modelos de clasificación (en este caso para imágenes de rostros), permitiendo una segmentación más precisa de los datos. Al determinar automáticamente el número óptimo de grupos, se reduce la dependencia de otro tipo de parámetros, mejorando la generalización y reduciendo sesgos en el aprendizaje automático.

¿Qué dificultades presentan los métodos tradicionales para resolverlo? Los métodos tradicionales de clustering presentan diversas limitaciones al aplicarse a la clasificación de imágenes de rostros. En general, la mayoría de estos enfoques requieren un conocimiento previo significativo sobre la estructura de los datos y dependen de una interpretación manual de gráficos y métricas para determinar el número óptimo de clusters. Esto dificulta su aplicación en problemas donde la estructura de los datos no es clara. Algunas de las dificultades específicas incluyen:

El método del codo: Se basa en la observación de una gráfica de la suma de las distancias dentro de cada cluster (inercia intra-cluster) a medida que aumenta el número de clusters. Sin embargo, la detección del “punto de codo” es subjetiva y no siempre evidente, especialmente en conjuntos de datos con estructuras complejas o con distribuciones difusas.

El coeficiente de silueta: Mide qué tan bien se separan los clusters comparando la distancia promedio de un punto a los de su propio cluster con la distancia a los de otros clusters. Sin embargo, este cálculo es costoso computacionalmente y se vuelve poco práctico para conjuntos de datos grandes como bases de imágenes de rostros, además de que su interpretación puede no ser clara en casos donde los clusters no sean compactos y bien separados.

DBSCAN y Mean Shift: Estos métodos pueden encontrar automáticamente el número de clusters sin necesidad de predefinirlo, pero dependen de parámetros como el radio de búsqueda o la densidad mínima de puntos para formar un cluster. En imágenes de rostros, donde la variabilidad en iluminación, expresión facial y ángulos de captura es alta, definir estos parámetros correctamente es un desafío y puede llevar a malos resultados.

K-means: Es uno de los métodos más utilizados, pero requiere que el número de clusters sea definido antes de ejecutar el algoritmo.

3 Referencias a trabajos previos

A. M. N. Al Radhwani y Z. Y. Algamal proponen una versión mejorada del algoritmo K-means incorporando el Algoritmo de Luciérnagas (FFA) para hacer más eficiente la selección de centroides y evitar que el agrupamiento se quede atascado en soluciones subóptimas. Gracias a su enfoque adaptativo, el FFA

explora mejor el espacio de soluciones, lo que se traduce en una clasificación de datos más precisa y estable en comparación con la versión tradicional de K-means y otras variantes.

J. Senthilnath, S. N. Omkar y V. Mani exploran cómo el Algoritmo de Luciérnagas (FA) puede mejorar la agrupación de datos en comparación con otros métodos bioinspirados, como Artificial Bee Colony (ABC) y Particle Swarm Optimization (PSO). Para evaluar su desempeño, probaron el FA en 13 conjuntos de datos del repositorio UCI y analizaron su precisión en la clasificación. Los resultados muestran que el FA es más eficiente, ya que optimiza mejor la selección de los centros de los clústeres y reduce los errores de clasificación.

Suryanarayana explora cómo mejorar el algoritmo K-Means utilizando el Algoritmo de Luciérnagas (AFA). K-Means es ampliamente utilizado para agrupar datos, pero puede quedar atrapado en soluciones subóptimas debido a su sensibilidad a los puntos iniciales. Para abordar este problema, el estudio combina K-Means con AFA, permitiendo que las luciérnagas optimicen la selección de centroides y mejoren la calidad de los clusters. Las pruebas con cinco conjuntos de datos del repositorio UCI muestran que esta combinación supera a K-Means y a Particle Swarm Optimization (PSO) en precisión y reducción de errores de clasificación[3].

4 Explicación de los algoritmos bioinspirados elegidos

Firefly Algorithm (FA) El Firefly Algorithm es un algoritmo de optimización basado en el comportamiento de luciérnagas, donde los individuos en la población emiten señales luminosas para atraer a otros en función de su intensidad, la cual se asocia con la calidad de la solución encontrada.

Atracción adaptativa: Las luciérnagas más brillantes (mejores soluciones) atraen a otras, lo que favorece la convergencia hacia regiones prometedoras del espacio de búsqueda. **Exploración global y local:** Al combinar movimientos dirigidos hacia soluciones óptimas con una exploración aleatoria, FA equilibra la explotación de buenas configuraciones y la exploración de nuevas posibilidades. **Aplicabilidad en clustering:** En este contexto, FA se emplea para encontrar el número óptimo de clusters evaluando diferentes particiones de los datos y ajustando dinámicamente la agrupación según criterios de calidad, como la dispersión intra-cluster y la separación entre clusters.

Particle Swarm Optimization (PSO) El Particle Swarm Optimization (PSO) se inspira en el comportamiento colectivo de enjambres de aves y bancos de peces, donde cada partícula en el sistema ajusta su posición basándose en su experiencia individual y en la de sus vecinas.

Inteligencia colectiva: Las partículas se mueven en el espacio de búsqueda guiadas por su mejor solución encontrada (memoria personal) y por la mejor solución global del enjambre. **Exploración eficiente:** La combinación de aprendizaje individual y social permite a PSO adaptarse dinámicamente a cambios

en la estructura de los datos sin requerir una exploración exhaustiva de todas las posibilidades. Aplicación en clustering: En este problema, cada partícula representa una posible solución de clustering, y su movimiento en el espacio de búsqueda ajusta los parámetros para mejorar la separación y cohesión de los grupos.

5 Definición de los Datos a Utilizar

5.1 Fuente de los datos

Se utilizará el conjunto de datos `fetch_olivetti_faces`, que contiene imágenes de rostros en escala de grises con dimensiones uniformes, ideal para pruebas de clustering en reconocimiento facial.

5.2 Características de los datos

- **Formato:** Imágenes en escala de grises, tamaño 64x64 píxeles.
- **Variables clave:**
 - Intensidad de píxeles como entrada para el clustering.
 - Posibles etiquetas para validación del modelo.

5.3 Posibles problemas con los datos

- **Ruido:** Diferencias en expresión facial pueden afectar la clasificación.
- **Balanceo de clases:** Número similar de muestras por individuo, pero con variaciones en iluminación y ángulos.

6 Referencias

[1] A. M. N. Al Radhwani y Z. Y. Algamal, "Improving K-means clustering based on firefly algorithm," *Journal of Physics: Conference Series*, vol. 1897, no. 1, p. 012004, May 2021, doi: 10.1088/1742-6596/1897/1/012004.

[2] J. Senthilnath, S. N. Omkar, y V. Mani, "Clustering using firefly algorithm: Performance study," *Swarm and Evolutionary Computation*, vol. 1, no. 3, pp. 164-171, 2011, doi: 10.1016/j.swevo.2011.06.003.

[3] L. P. . K., G. . Suryanarayana, N. . Swapna, T. . Bhaskar, and A. . Kiran, "Optimizing K-Means Clustering using the Artificial Firefly Algorithm", *Int J Intell Syst Appl Eng*, vol. 11, no. 9s, pp. 461-468, Jul. 2023.